



开放数据中心标准推进委员会
Open Data Center Committee

[编号 ODCC-2021-03002]

S³IP - 硬件基础功能规范

(Simplified Switch System Program- Hardware Basic Function Specification)

www.ODCC.org.cn

开放数据中心标准推进委员会

2021-06-30 发布

目录

前 言	III
引 言	IV
1 范围	1
2 规范性引用文件	2
3 术语、定义和缩略语	3
4 硬件基础功能规范	5
4.1 光模块访问控制	5
4.2 设备管理网口和内部管理网络	6
4.3 复位、中断及上下电	6
4.4 风扇控制	7
4.5 温度监控	7
4.6 二次电源监控	7
4.7 PSU 监控	8
4.8 固件备份升级	8
4.9 RTC 时钟	8
4.10 FRU 和 TLV	9
4.11 看门狗	9
4.12 系统 LED	9
4.13 硬件版本	10
4.14 BIOS 设定	10

本规范用词说明	10
---------------	----



前 言

本规范共分 4 章，主要技术内容有：范围、规范性引用文件、术语、硬件基础功能规范。

ODCC-2021-03002 文档主要描述硬件基础功能规范，提供硬件底层能力支撑 API 接口标准化落地，隶属于 S³IP 软硬件规范系列之一。S³IP 软硬件规范还包括 Sysfs 规范(开源 SONIC 和 FW 的 API 接口规范化)，以及 PIT 规范，提供产测和验收手段，检验设备是否符合 S³IP 规范。

本规范由 S³IP 项目组负责管理和具体技术内容的解释，硬件基础功能规范主要作者为黄一元。本规范在执行过程中，请各单位结合工程实践，认真总结经验，如发现需要修改或补充之处，请将意见和建议 Mail 至 fangbo.zfb@alibaba-inc.com。

以供今后修订时参考。

主编单位： 百度、阿里、腾讯、美团、京东、快手

参编单位、审核人（排名按照姓名字母排序）： 崔鹏(腾讯)、陈虎(美团)、程传胜(腾讯)、杜海峰(快手)、黄一元(阿里)、李华(阿里)、李竞(百度)、沈大勇(腾讯)、申路(美团)、孙勇峰(腾讯)、田上飞(腾讯)、王超(阿里)、文权(腾讯)、王家富(京东)、吴教仁(快手)、王永灿(阿里)、夏云磊(京东)、杨光(腾讯)、朱芳波(阿里)、郑磊(美团)、占志敏(阿里)

引 言

随着互联网的高速发展，数据中心的规模也随之爆发式增长，全球数据中心总数量几十万个，超大型数据中心数量几百个。数据中心内部、不同数据中心之间海量数据互联，Machine to Machine以及Machine to User的高带宽、低延迟的持续提升需求，需要依靠网络实现，作为承担网络发展的载体交换机，近几年市场出现一些明显变化：1、互联网客户纷纷自研白盒交换机、构建自己的基础设施能力，针对各自应用场景“精”“简”化设计，研发模式基本采用轻量化模式；2、中国互联网客户非常默契选用开源SONIC作为交换机OS，构建各家自研网络。轻量化研发模式需要将交换机重投入的底层技术如硬件、驱动、FW交给ODM/OEM实现，ODM/OEM提供白盒设备给互联网公司porting各自OS上线。不同厂商设备之间设计存在差异，导致OS porting不同厂商设备花费资源较多；ODM/OEM厂商提供得底层驱动/FW融合了多个客户需求，导致非互联网客户必须的需求特性被带入互联网的应用场景，对线上稳定性会产生影响，对于互联网客户而言始终是个隐患。通过标准化交换机OS和底层驱动/FW/硬件基础设计的接口部分设计，可以简化OS porting厂商设备难度，降低互联网客户资源投入；同时，国内互联客户OS全切换到SONIC后，标准化OS和底层FW/驱动/硬件基础功能之间接口部分设计，屏蔽不同厂商设备之间的差异，技术完全可行。

本规范提出硬件基础功能规范，用于规范化交换机硬件的基本功能。

本规范旨在：通过本标准引导互联网白盒交换机设计，统一软硬件设计规范，实现上层OS porting白盒化交换机便利化；同时，S³IP项目组成员部署基于同一标准设计的交换机，扩大标准交换机应用规模，能更容易发现和解决问题，提升设备上线稳定性。

S³IP 硬件基础功能规范

1 范围

本规范提出交换机的硬件功能标准，内容如下：

- 硬件基础功能规范；

自2020年11月开始S³IP在ODCC立项，BAT+美团+京东+快手进行了将近一年的规范讨论和研究，本标准涉及内容当前均已在各家自研设备上落地，得到了验证，但并未统一成六家共同遵守的规范。通过S³IP项目，后续各家自研交换机将围绕统一的标准规范进行设计。

本规范是集体智慧的结晶，希望规范中不当之处得到业界同仁的指正，编者将吸取大家的宝贵意见再次修订本规范，期待本规范再版时更加完整、严谨、丰富。

2 规范性引用文件

下列文件对于本文件的应用是必不可少的，凡是注日期的引用文件，仅注日期的版本适用于本文件。凡是不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

1. SFF-8024 SFF Module Management Reference Code Tables.
2. SFF-8472 Management Interface for SFP+
3. SFF-8419 SFP+ Power and Low Speed Interface
4. SFF-8636 Management Interface for 4-lane Modules and Cables
5. SFF-8679 QSFP+ 4X Hardware and Electrical Specification
6. Common Management Interface Specification (CMIS)
7. FRU Spec. Platform Management FRU Information Storage Definition v1.0

3 术语、定义和缩略语

数据中心 Data center

为集中放置的电子信息设备提供运行环境的建筑场所，可以是一栋或几栋建筑物也可以是一栋建筑物的一部分，包括主机房、辅助区、支持区和行政管理区等。

交换机 Switch

一种用于电（光）信号转发的网络设备。它可以为接入交换机的任意两个网络节点提供独享的电信号通路。

操作系统 OS

操作系统 (operation system, 简称 OS) 是管理计算机硬件与软件资源的计算机程序。操作系统需要处理如管理与配置内存、决定系统资源供需的优先次序、控制输入设备与输出设备、操作网络与管理文件系统等基本事务。操作系统也提供一个让用户与系统交互的操作界面。

光端口 Optial Fiber Connector

光纤接口简称，应用于机房、机柜等大型设备的一个光纤带宽接口。

配置接口 Console

插入 Console 线可直接连接至交换机，对交换机进行配置。

Host CPU

交换机系统中的主控 CPU，用于管理和控制主交换芯片。

BMC

Baseboard Management Controller，在交换机系统中负责系统管理和控制，监控温度、电源等系统状态并负责异常告警和处理。独立于 Host CPU。

二次电源

这里指交换机系统中，各类芯片所需的直流低压电源，区别于系统外部供电的 220V

交流或者高压直流电源。通常使用 DC/DC 芯片把 PSU 输出的 12V 电压转变为芯片所需的各种低电压。

PSU

Power Supply Units (PSU), 交换机电源模块, 用于将 220V 交流或高压直流输入转变成 12V 直流电压。

CPLD

是 Complex PLD 的简称, 顾名思义, 其是一种较 PLD 为复杂的可编程逻辑器件。采用 CMOS EPROM、EEPROM、FLASH 和 SRAM 等编程技术, 构成了高密度、高速度和低功耗的可编程逻辑器件。

FPGA

Field Programmable Gate Array 的缩写, 即现场可编程门阵列, 它是在 PAL、GAL、EPLD 等可编程器件的基础上进一步发展的产物。用户可对 FPGA 内部的逻辑模块和 I/O 模块重新配置, 以实现用户的逻辑。FPGA 的编程数据放在 Flash 芯片中, 通过上电加载到 FPGA 中, 对其进行初始化。

TLV

TlvInfo EEPROM, ONIE 兼容的交换机系统所需要支持的 EEPROM 信息格式。存储的数据包括分配给系统的 MAC 地址、序列号、制造日期等信息。

4 硬件基础功能规范

4.1 光模块访问控制

- 4.1.1 QSFP 类型的光模块控制：支持对 ModPrsL, IntL, ResetL, ModSelL, LPMode 信号的实时电平读取；支持对 ResetL, LPMode 信号的电平控制；ModSelL 可直接拉低到 GND。
- 4.1.2 SFP 类型的光模块控制：支持对 TX Fault, MOD_ABS, RX_LOS, TX Disable 信号的实时电平读取；支持对 TX Disable 信号的电平控制。
- 4.1.3 光模块端口 LED 支持橙绿双色显示,每种颜色分别支持常亮、灭、和闪烁三种模式。
- 4.1.4 系统启动后光模块端口 LED 状态由 CPLD 控制，交换芯片初始化完成后 LED 状态由 SDK/软件控制。
- 4.1.5 任意光模块端口的 I2C 挂死不能影响系统对于其他光模块端口的访问。
- 4.1.6 支持 NACK 重试：当对光模块的 I2C 访问过程中出现 NACK 失败后，需要停止本次操作并等待一定间隔后再次发起一次或多次完整的访问重试，累计的重试等待间隔需大于 40ms。重试过程不能复位光模块。
- 4.1.7 每个光模块的 I2C 通道需要隔离，可通过 9548 芯片对光模块 I2C 通道进行扩展和隔离。同一个 I2C Master 最多管理 8 个光模块，即一个 I2C Master 通过一个 9548 管理 8 个光模块。
- 4.1.8 光模块的访问速率：对于端口 SerDes 速率等于或小于 25G NRZ 的光模块的 I2C 访问速率只需支持 100KHz 模式，对于端口 SerDes 速率等于或大于 56G PAM4 的模块的 I2C 访问需同时具备 100KHz 和 400KHz 模式。100K 和 400K 模式的切换

软件可控。100K 速率可接受范围:98KHz~100KHz,400K 速率可接受范围:390KHz-400KHz

4.2 设备管理网口和内部管理网络

4.2.1 通过设备管理网口可以访问 Host CPU 管理网口。

4.2.2 对于配置 BMC 的设备,内部管理交换网络提供设备管理网口、Host CPU 管理网口和 BMC 管理网口的网络互通,且内部管理网络需具备二层 VLAN 能力。

4.2.3 对于配置 BMC 的设备,通过设备管理网口和内部管理交换网络可访问 BMC 管理网口,且不受 Host CPU 状态的影响。

4.2.4 对于配置 BMC 的设备,CPU 和 BMC 可以通过内部管理交换网络互通。

4.3 复位、中断及上下电

4.3.1 对具有 RESET 信号的芯片,需提供独立复位控制能力。

4.3.2 对具有 INT 信号的芯片,需提供中断信号实时电平状态寄存器和中断信号沿锁存状态读取和清除寄存器。

4.3.3 中断的汇聚上报:能够通过硬件引脚和 PCIe 上报至 Host CPU,在具有 BMC 的设备上同时能够通过硬件引脚上报至 BMC;

4.3.4 中断的汇聚上报:可通过屏蔽寄存器对各个中断源进行独立屏蔽和整体屏蔽;

4.3.5 关键芯片和模块如主交换芯片、光模块、PHY、FPGA 的电源单独可控(可单独打开或关闭),不得与其他芯片或模块混用电源。

4.3.6 对配置 BMC 的设备,BMC 子系统和系统其他部分的相互保持独立,电源状态、健康状况互不影响。

4.4 风扇控制

4.4.1 支持风扇转速 PWM 调节。

4.4.2 支持风扇实时转速的读取，对于多转子的风扇需支持对单个转子转速的独立读取。

4.4.3 风扇控制程序挂死或失效时风扇能够自动满转。

4.4.4 支持对风扇 FRU 信息的读取。

4.4.5 风扇模组状态 LED 支持橙绿双色显示。每种颜色支持常亮、灭、和闪烁三种模式。

4.5 温度监控

4.5.1 支持进风口和出风口温度的读取，并需确保入风口温感读值和实际进风口温度的温差在 3 度之内。

4.5.2 支持主交换芯片内部结温的读取，对于主交换芯片所支持的所有结温读取方式，如内部 thermal diode, I2C 等，必须全部支持。

4.5.3 外部传感器温度精度不超过 0.5 度。

4.5.4 支持主 CPU 结温、光模块温度、DIMM 温度、SSD 温度、PSU 模块温度的读取。

4.6 二次电源监控

4.6.1 支持二次侧所有电源电压的监控，包括：DC/DC 的输出电压；LDO 的输出电压；Efuse 的输出电压。

4.6.2 电压监控精度不超过 $\pm 1\%$

4.6.3 支持二次侧所有电源 PG 信号的实时状态读取

4.6.4 支持二次侧所有电源 PG 的失效监测，需存储各个电源 PG 失效点的相对时间。

4.6.5 支持主芯片电源电流的监控，如交换芯片，PHY。

4.7 PSU 监控

4.7.1 PSU 的固化信息，如 PN,SN,风向,硬件版本，固件版本，需支持通过 PMBUS 或者 FRU 进行读取。

4.7.2 支持通过 PMBUS 对 PSU 的实时信息的读取，包括：输入电压类型(AC 或 DC)，输入电压，输出电压，输出电流，温度。

4.7.3 支持 PSU PWOK 和 ACOK 的实时状态读取和中断上报。

4.8 固件备份升级

4.8.1 CPU 的 boot flash 和 BIOS 支持物理双备份，并且在主固件或主存储器件失效的时候能够自动切换到备存储器件启动。同时支持主备固件的强制切换。

4.8.2 BMC 的 boot flash 支持物理双备份，并且在主固件或主存储器件失效的时候能够自动切换到备存储器件启动。同时支持主备固件的强制切换。

4.8.3 主 CPLD 和 FPGA 支持固件备份，在主固件失效的时候能够自动切换到备份固件启动。这里主 CPLD 指的是负责系统上下电控制的 CPLD。

4.8.4 通过 BMC 和 CPU 均可对以下芯片的在线固件升级：主备 Boot Flash，主备 BIOS，CPLD 主备固件，FPGA 主备固件，PHY、Switch 的外部 Flash。

4.9 RTC 时钟

4.9.1 CPU 支持电池供电的 RTC 时钟。

4.9.2 BMC 支持电池供电的外部 RTC 时钟，可与 CPU RTC 共用电池。

4.9.3 BIOS 和 OS 时间统一设定为 UTC 时间。

4.10 FRU 和 TLV

4.10.1 PSU、风扇模组、各个主要板卡需要有 FRU EEPROM 和 TLV EEPROM 进行保存。

系统的 FRU 信息可以保存到其中一个板卡的 FRU EEPROM 中。

4.10.2 TLV EEPROM 中的信息值必须和系统 FRU 内的信息值保持一致。

4.10.3 FRU 内容定义如表 5.1

表 5.1 FRU 内容定义

区域	字段	描述	类型	系统主EEPROM	各板卡EEPROM	风扇模块EEPROM	PSU EEPROM
The Common Header Area				参考标准 [1]	参考标准 [1]	参考标准 [1]	参考标准 [1]
The Internal Use Area							
The Chassis Info Area 适用于Chassis系统，chassis的背板EEPROM.盒式固定设备不适用	Chassis Type	TBD	TBD				
	Chassis Part Number	TBD	TBD				
	Chassis Serial Number	TBD	TBD				
	Chassis Extra 1	TBD	TBD				
The Board Info Area 各板卡PCBA生产信息	Mfg. Date / Time:	生产时间和日期。从0:00 hrs 1/1/96		实际时间日期	实际时间日期	实际时间日期 (如风扇模组有PCB)	
	Board Manufacturer:	供应商名称	String	供应商名称	供应商名称	供应商名称 (如风扇模组有PCB)	
	Board Product Name:	PCBA的名称, 比如"Base Board", "CPU"	String	供应商自定义	供应商自定义	供应商自定义 (如风扇模组有PCB)	
	Board Serial Number:	PCBA生产序列号	String	供应商自定义	供应商自定义	供应商自定义 (如风扇模组有PCB)	
	Board Part number:	PCBA P/N	String	供应商自定义	供应商自定义	供应商自定义 (如风扇模组有PCB)	
	Board FRU File ID:	不用					
	Board Extra 1:	PCBA的版本号	String	供应商自定义	供应商自定义	供应商自定义 (可选)	
The Product Info Area 产品信息, 只存在系统的主FRU EEPROM里。比如base/main board的EEPROM作为系统主FRU, 那么该EEPROM必须包含base/main board的板级信息和产品信息。其他的板子, 如switch board只需要包含板子信息	Manufacturer Name:	供应商名称	String	供应商名称		供应商名称	PSU厂家名
	Product Name:	产品PN(用户PN)	String	产品名		风扇产品名	PSU Product Name
	Product Part number:	供应商MPN	String	设备MPN		风扇MPN	PSU厂家P/N
	Product Version:	产品版本(供应商版本)	String	ROA/ROB.../P01/P02		风扇模组版本 (按照风扇FRU定义)	PSU版本
	Product Serial Number:	产品序列号	String	供应商自定义		风扇模组序列号	PSU 家序列号
	Product Extra 1:	产品生产日期, 格式: (YYYY-MM-	String	系统生产日期		生产日期	PSU生产日期
	Product Extra 2:	起始MAC地址 比如"0E0000000000",	hex	系统起始MAC地址			
	Product Extra 3:	MAC地址总个数	decimal	系统MAC地址总个数			
The Multirecord Area		PSU电源信息, 参考IPMI -. Platform Management FRU Information. Storage Definition v1.0					参考IPMI -. Platform Management FRU Information. Storage Definition v1.0

4.11 看门狗

4.11.1 CPU 和 BMC 支持外部看门狗

4.11.2 开启或关闭看门狗以及是否触发系统动作软件单独可配

4.11.3 喂狗周期软件可配

4.11.4 开门狗功能默认关闭, 由软件控制开启。

4.12 系统 LED

4.12.1 支持以下三种系统 LED 灯：SYS LED，指示系统状态；PWR LED，指示电源状态；
FAN LED，指示风扇状态。

4.12.2 每种灯支持黄绿双色，每种颜色支持常亮、灭、和闪烁三种模式。

4.13 硬件版本

4.13.1 主要板卡的硬件版本号通过所在板卡上的 CPLD 寄存器可读。

4.13.2 硬件版本通过 BOM 区分。

4.14 BIOS 设定

4.14.1 使用 X86 CPU 的系统 BIOS 默认设定如下，BIOS 菜单提供修改设定的选项：

C-State => Disable

Package C State => C0/C1

Hardware P-state(HWPM) => Disable

Speedstep EIST =>Disable

Turbo Boost =>Disable

T-state =>Disable

PCIE ASPM Support =>Disable

本规范用词说明

为便于在执行本规范条文时区别对待，对要求严格程度不同的用词说明如下：

1) 表示很严格，非这样做不可的用词：

正面词采用“必须”，反面词采用“严禁”。

2) 表示严格，在正常情况下均应这样做的用词：

正面词采用“应”，反面词采用“不应”或“不得”。

3) 表示允许稍有选择，在条件许可时首先应这样做的用词：

正面词采用“宜”，反面词采用“不宜”；

表示有选择，在一定条件下可以这样做的用词，采用“可”。

本规范中指明应按其他有关标准、规范执行的写法为“应符合,,,的规定”或“应按,,,执行

本页为规范最后一页



WWW.ODCC.ORG.CN